Ninf システムにおける ジョブスケジューラの実装と 予備的評価

竹房あつ子，中田秀基，合田憲人，
小川宏高，松岡聡，長嶋雲兵

http://ninf.etl.go.jp/

グローバルコンピューティング

- ネットワーク技術の発展

  計算・情報資源を利用した広域並列分散計算

  → **グローバルコンピューティング**

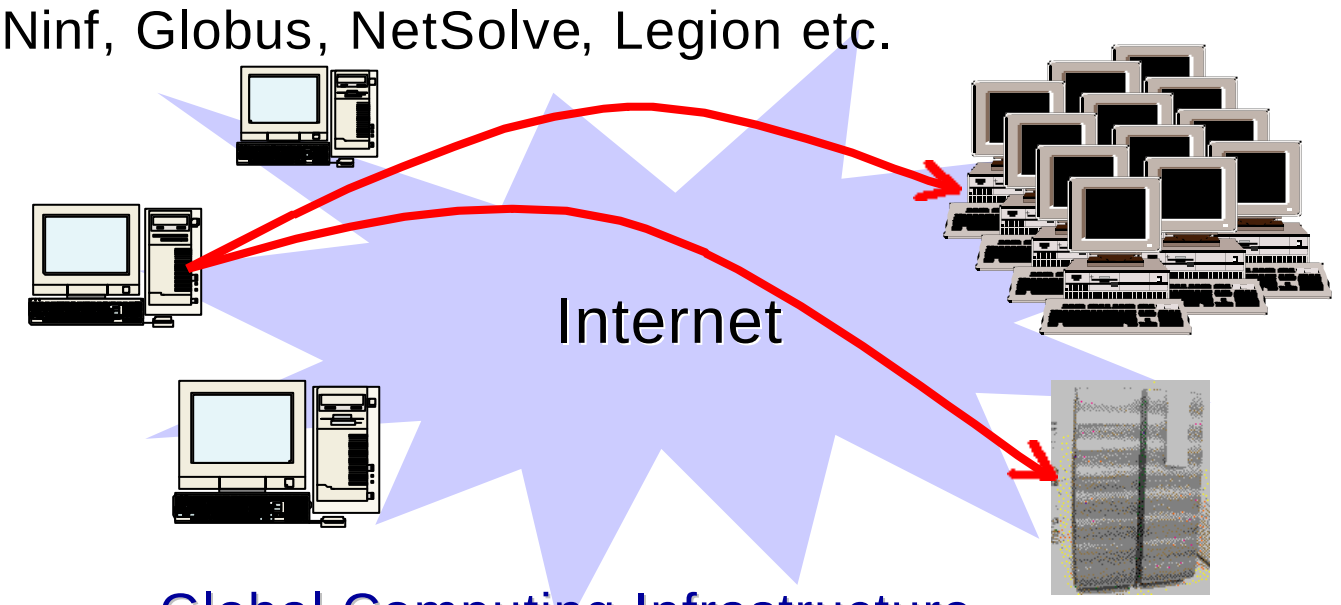

グローバルスケジューリング

- 不均質かつ変動する環境下で，ユーザの要求性能を満たす→ **グローバルスケジューリング**
- **ジョブスケジューリング**

  システム全体の複数ジョブの総実行時間の短縮

  – Matchmaker(Condor), Nimrod/G
- **アプリケーションスケジューリング**

  単一プログラムの応答時間の短縮

  – AppLeS, Prophet

→ジョブ / アプリケーションスケジューリングをバランスよく採り入れる

研究の目的と発表内容

- スケジューリングフレームワークの提案
- Ninf のMetaServerアーキテクチャの実装とスケジューリング手法の予備的評価

- 発表内容
  - スケジューリングフレームワークの概要
  - Ninf MetaServer アーキテクチャ
  - スケジューリング手法の評価 (実測・シミュレーション)
  - まとめ

ジョブ/アプリケーション スケジューリング

- **ジョブスケジューリング**
  - ユーザの要求(デットライン，利用計算機，…)を満たす
  - 複数ユーザのRequestの総所要時間を最短にする

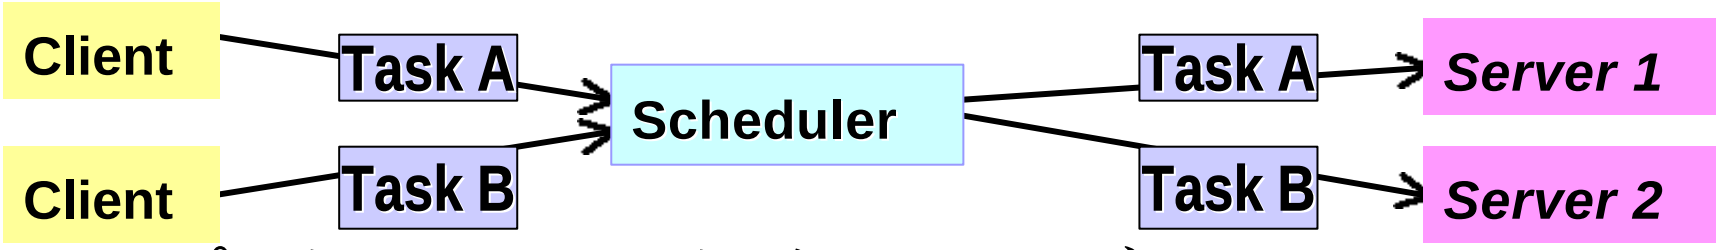

- **アプリケーションスケジューリング**
  - アプリケーションを適切に分割
  - 各タスクの応答時間を短くする

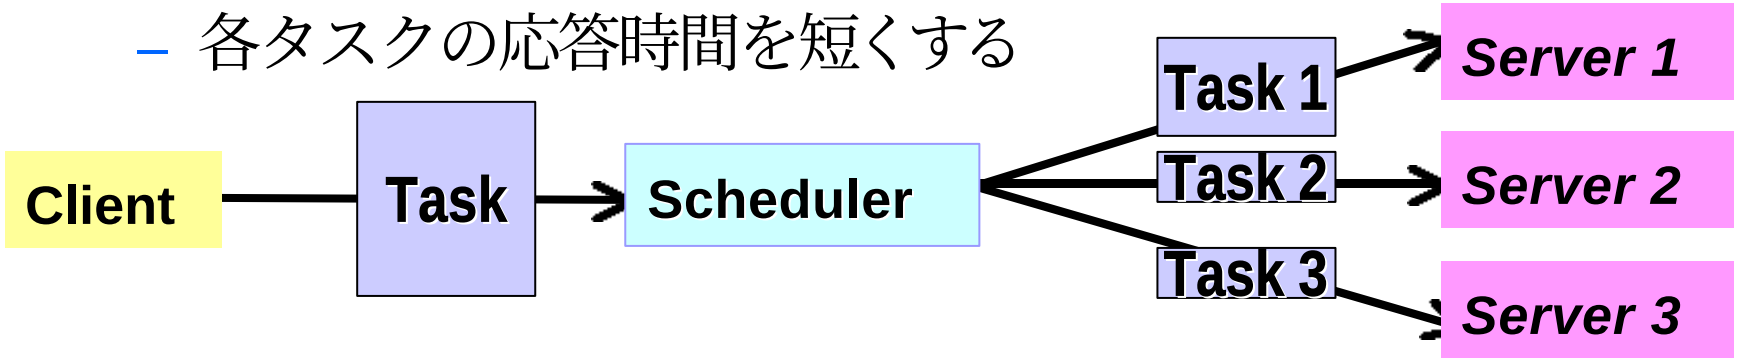

スケジューリングフレームワーク

- Job / Application Resource Allocator
  - 単一アプリケーションを複数並列タスク(Network Task)に分割
- Low-Level Scheduler
  - Network Taskをサーバへスケジューリング
    サーバの負荷，ネットワークのスループット情報
- Resource Monitor / Predictor
  - リソース情報を提供
    - 負荷･スループットのモニタ
    - リソース情報の管理
    - リソース情報の予測

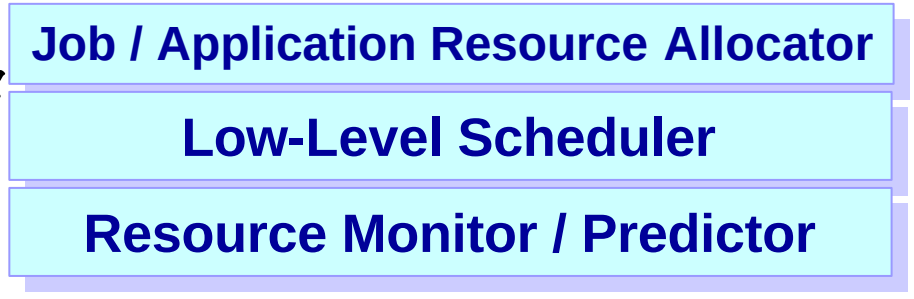

Network Task スケジューリング

- ネットワークスループットモニタ
  - 各クライアント・サーバ間の
    スループットを測定
- 計算リソースのための負荷モニタ
  - 1つのノードで負荷情報を収集
- リソース情報管理
- リソース状況プレディクタ
- スケジューラ
  - Network Taskの割り当て

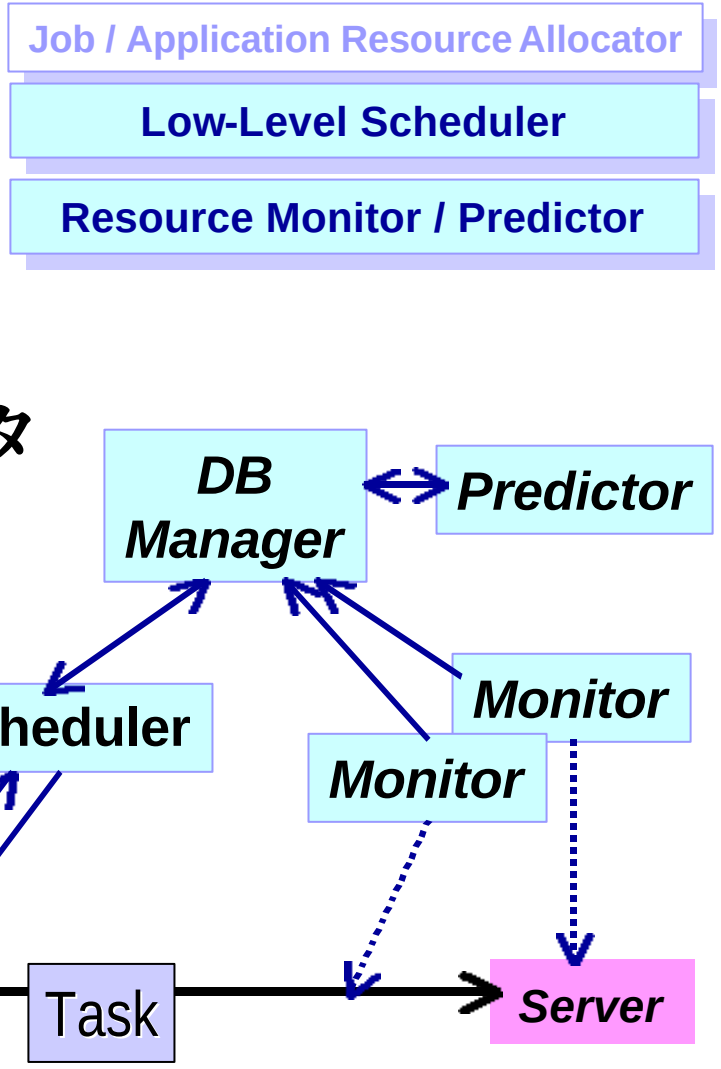

Ninf MetaServer アーキテクチャ

- Ninfシステム
  - RPCベースのグローバルコンピューティングシステム
  - **MetaServer**により，スケジューリングをサポート
- MetaServer のコンポーネント
  - 計算リソースの **Load Monitor**
  - **Client Proxy**
    - ネットワークのモニタリング
    - firewall のためのプロキシ
  - リソース情報 **DB Manager**
  - リソース **Scheduler**

Network Task スケジューリング

MetaServerの処理プロセス

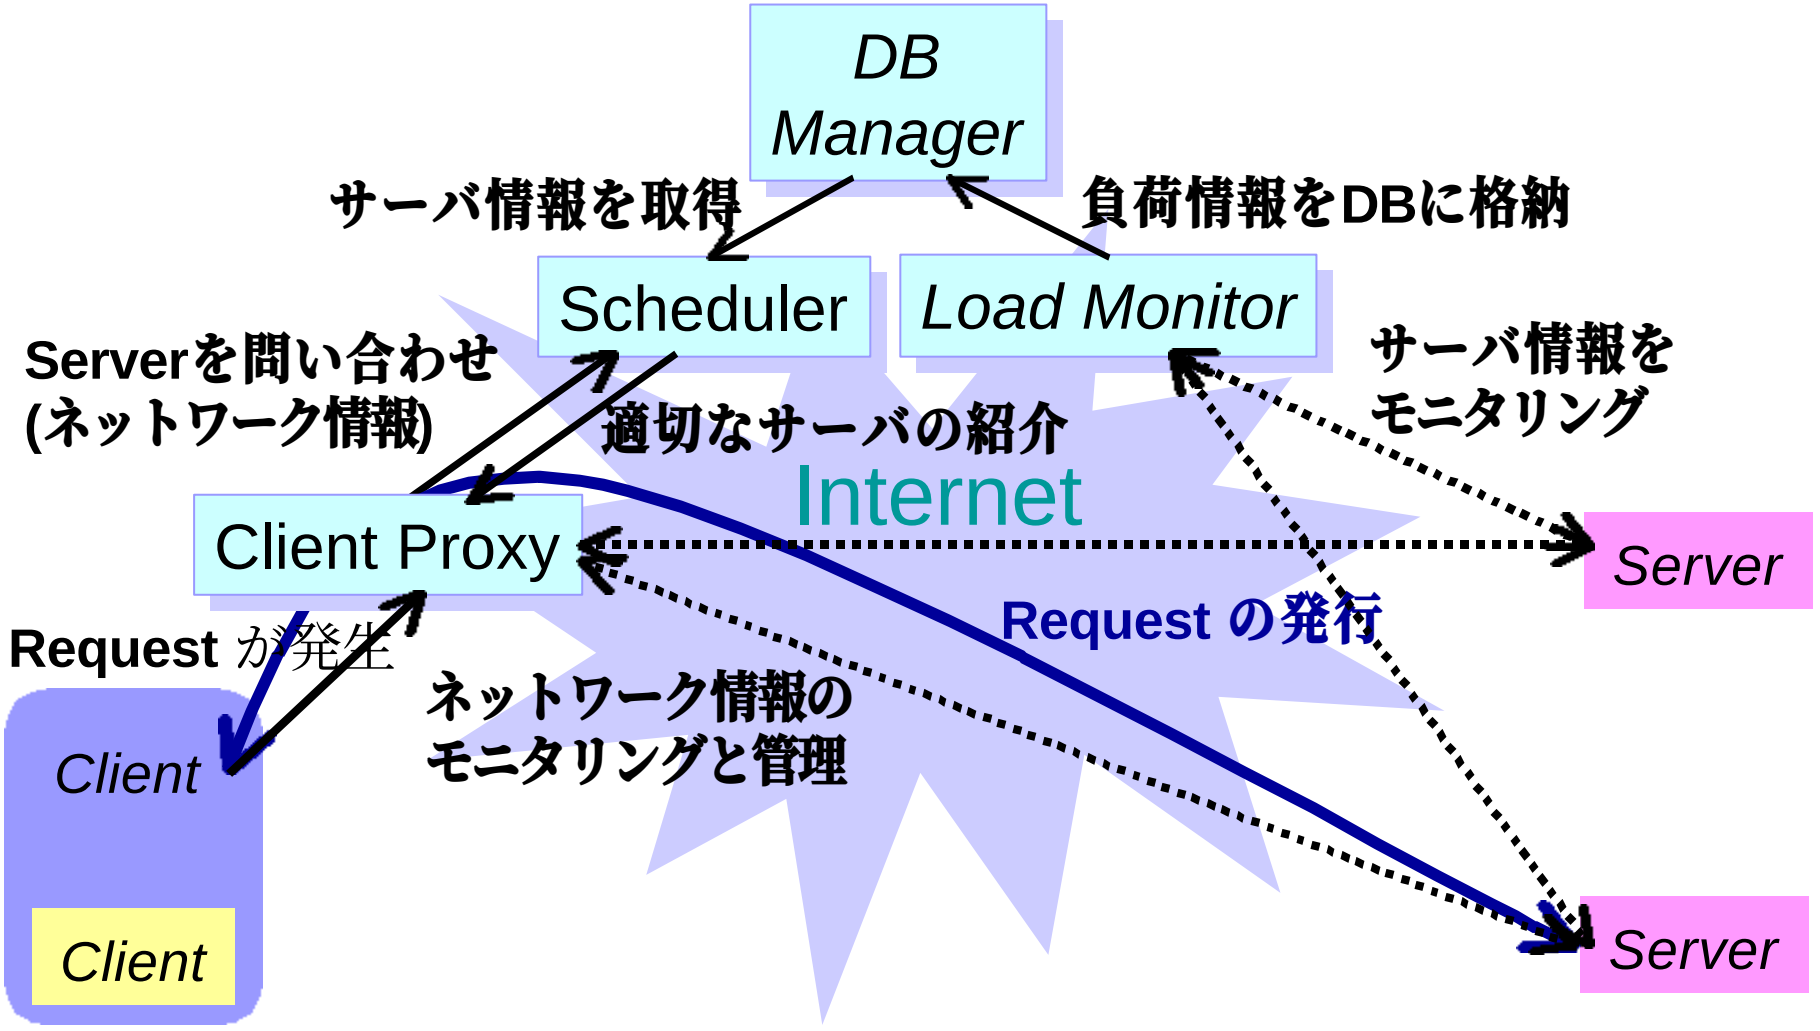

Schedulerでのサーバ選択

```
Define linpack(
IN double a[lda:n][n],
IN int lda, n,
OUT int ipiv[n],
OUT int *info
INOUT double b[n])
CalcOrder (((n^3)*2)/3)+(2*(n^2))
```

Ninf IDL

- ClientProxy
  - 通信スループット
- DB Manager
  - 計算サーバ性能
- Ninf IDL
  - 通信量
  - 演算数

スケジューリングポリシに
従いサーバを選択

スケジューリング手法の予備的評価

- Ninf MetaServer を用いた評価 (実環境)
  - Client, ClientProxy ― 東工大 (東京)
  - Scheduler, DB Manager, Load Monitor ― 東工大
  - Server1 ― 電総研 (つくば)
  - Server2 ― 東工大
- シミュレーションによる評価
  - Client, MetaServer, Server が分散した環境

スケジューリング手法

- スケジューリング
  - Round Robin : **RR**

    サーバを Round Robin で割り当てる
  - 負荷 + 計算性能 : **LOAD**

    (L + 1) / P が最小となるサーバを割り当てる

    (**L** : 平均負荷, **P** : サーバの性能)
  - 負荷 + 計算性能 + 通信スループット : **LOTH**

    演算数 / (P / (L + 1)) + 通信量 / T が最小となるサーバを割り当てる (**T** : 通信スループット)
- リソースの予測
  - 通信スループット : T / ネットワークを共有するジョブ数
  - サーバの負荷 : ジョブの割り当て→負荷=負荷 + 1

実測による評価環境

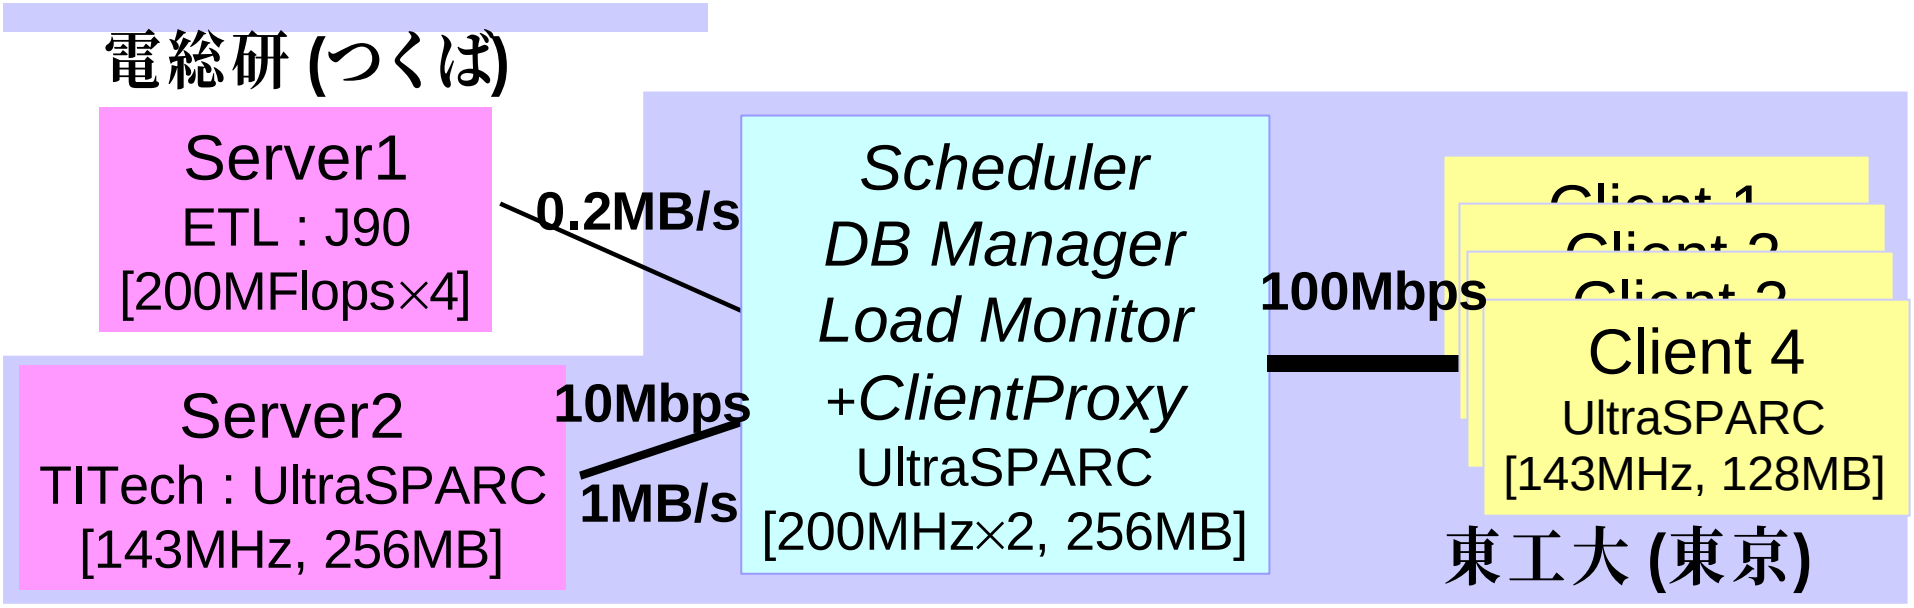

- 計算ルーチン : Linpack (n = 600, 固定)

  演算数 $2/3n^3+2n^2$, 通信量 $8n^2+20n+O(1)$ [byte]

- Request 発行間隔 : 指数分布

  – **CaseA** : [Requestの所用時間] + *interval*

  – **CaseB** : [Requestの所用時間] × 2 + *interval*

Requestが頻繁に発生

実測による評価結果 (CaseA)

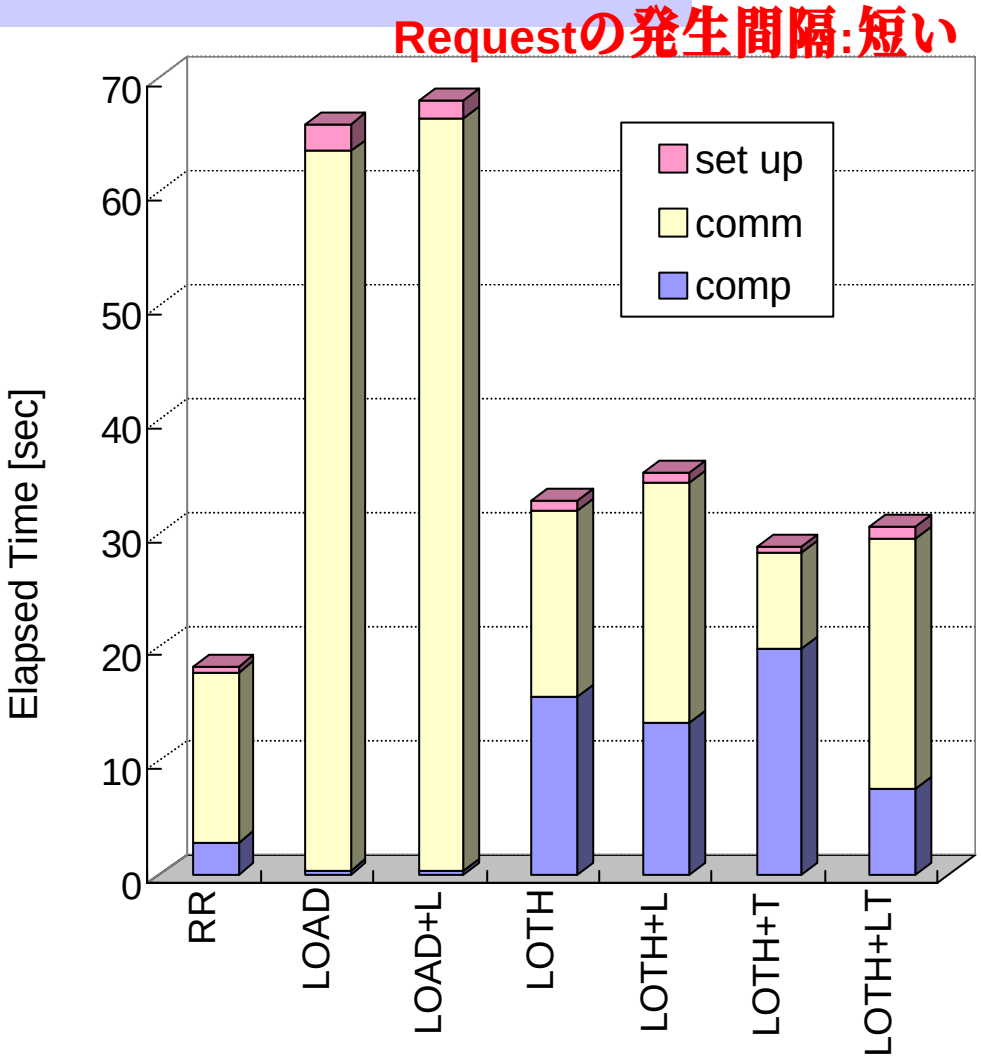

- RRが1番よい性能

→ LOTHではリソースの干渉

- Loadの性能は悪い

→すべてのRequestがJ90に投げられた

実測による評価結果 (CaseB)

Requestの発生間隔:長い

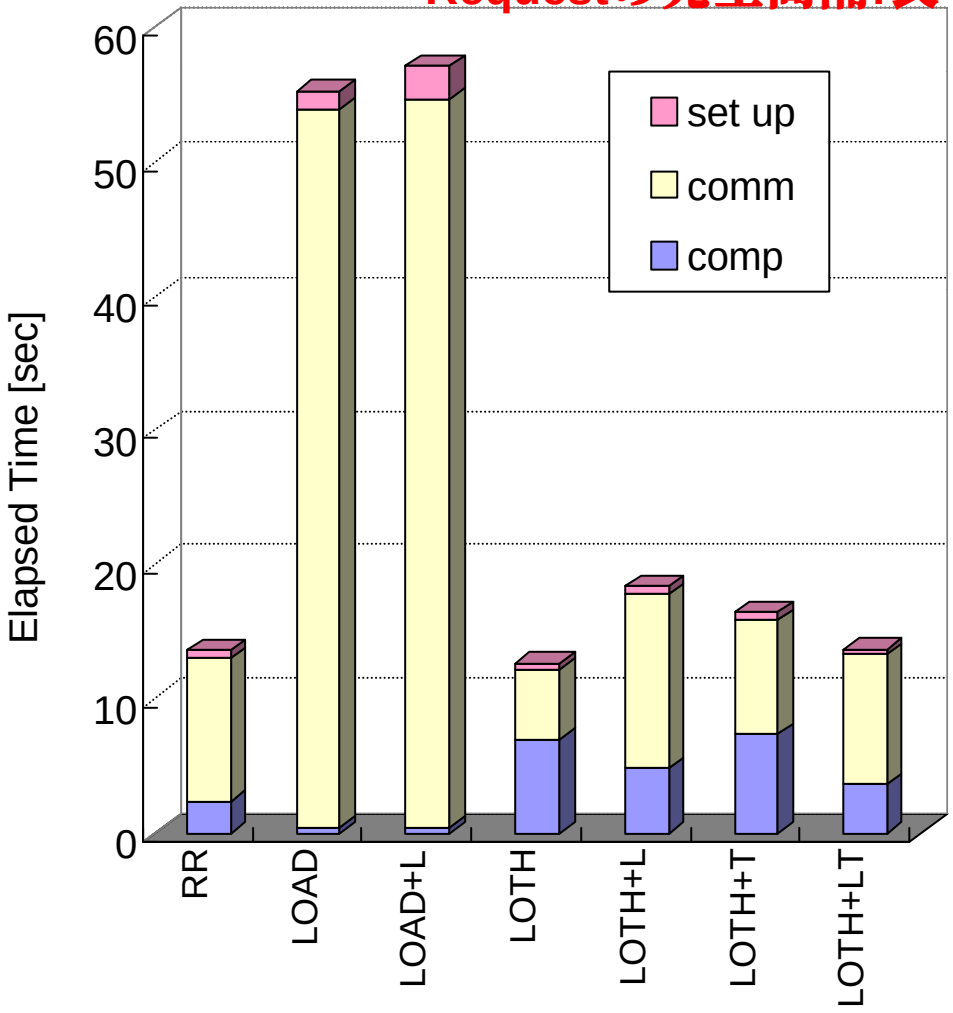

- LOADが悪い
- LOTHがよい性能

→ サーバ/ネットワークの負荷をバランスよく考慮

- LOTH+L, LOTH+Tの性能がよくない

→ 予測が単純

シミュレーションによる評価

- 性能評価モデル (JSPP‘98)
  - サーバ，ネットワークを待ち行列で表す
  - 様々なシステム構成，振舞いが表現可能
- 評価環境
  - 実測とほぼ同様の設定
  - クライアントは複数サイトに分散
  - 計算ルーチン:

    Linpack

    (n = 600, 固定)

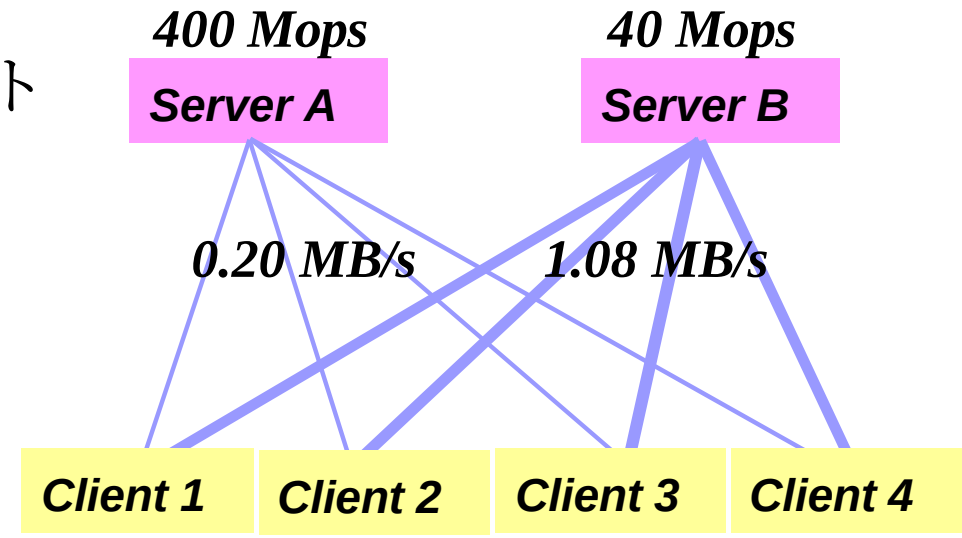

シミュレーションの設定パラメータ

- クライアント
  - Request の発行間隔 : 指数分布
    - **CaseA** : [Requestの所用時間] + *interval*
    - **CaseB** : [Requestの所用時間] × 2 + *interval*
  - 論理パケットサイズ = 0.1 [MB] (固定)
- ネットワーク (FCFS)
  - バンド幅 T_{net} = 1.5 [MB/s]
  - 外乱のデータ : 平均サイズ = 0.1 [MB]，ポアソン到着
- サーバ (FCFS)
  - 外乱のジョブ : 平均演算数 = 10 [Mflops]
    稼働率 10 [%]，ポアソン到着

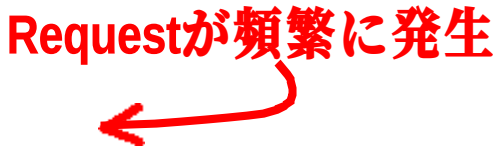

シミュレーションによる評価結果 (CaseA)

Requestの発生間隔:短い

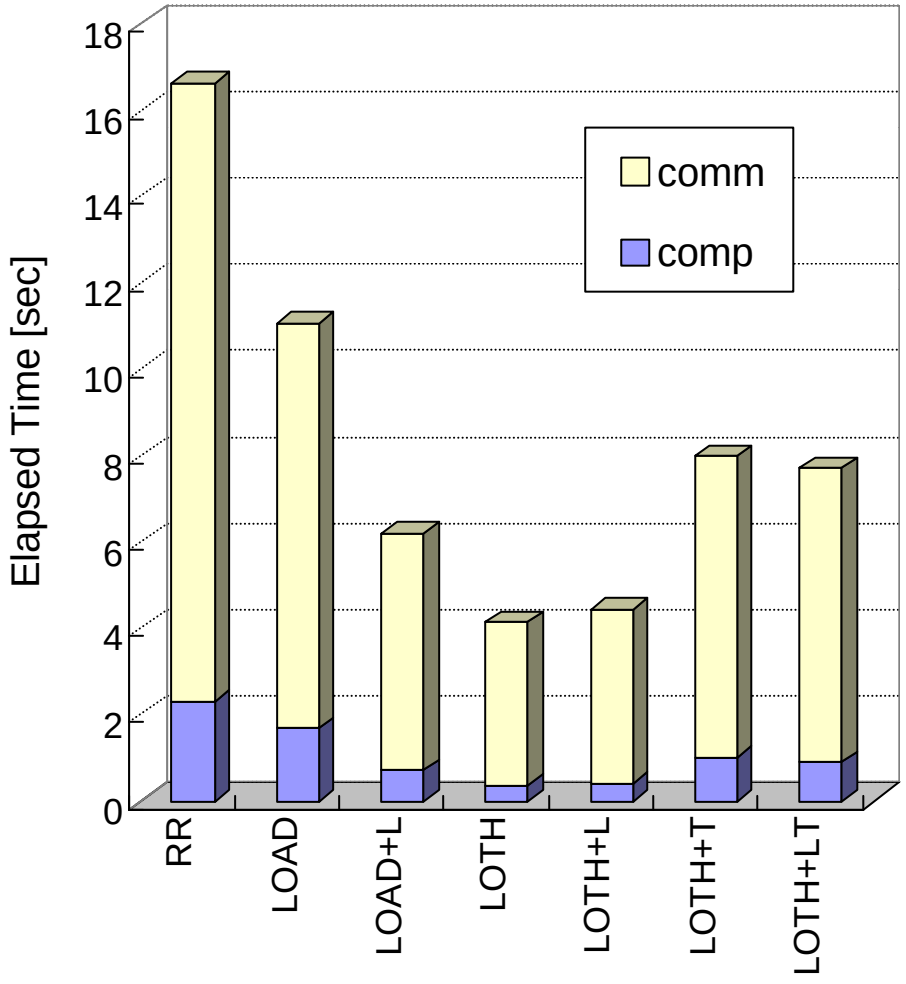

- LOTHで適切にスケジューリング

→リソース情報を適切に考慮

- 予測したものの性能はあまり良くない

→ 性能予測が不十分

- RRの性能が悪い

→ ネットワークの干渉がないため，相対的に悪い

シミュレーションによる評価結果 (CaseAとCaseBの比較)

CaseA : Requestの発生間隔**短い**

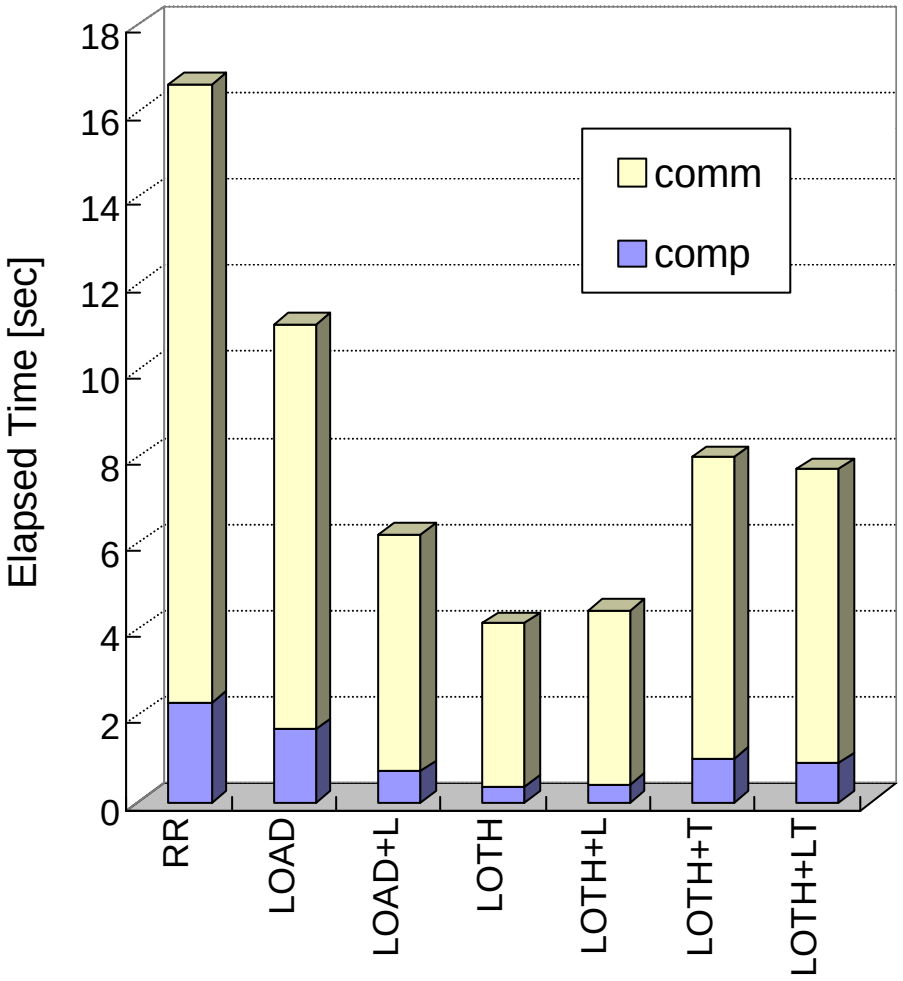

CaseB : Requestの発生間隔**長い**

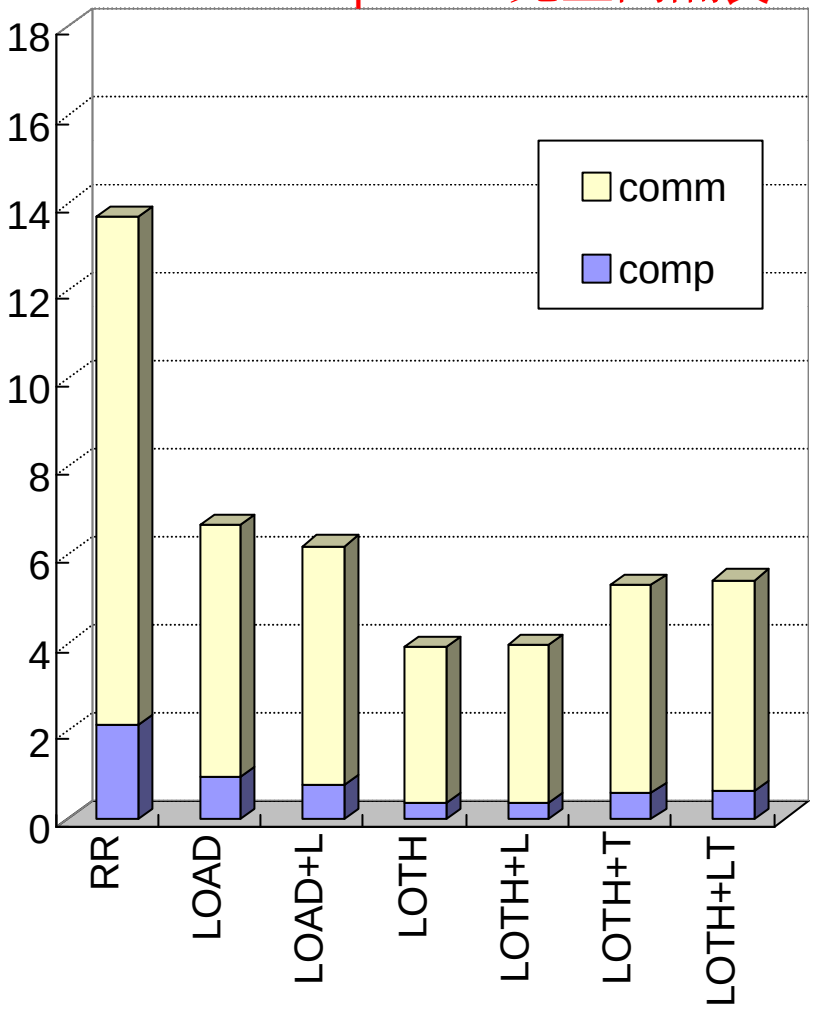

実測・シミュレーションによるスケジューリング手法の評価結果

- 実測
  - Request 発生間隔が短い場合，RRが1番よい性能
  - Request 発生間隔が長い場合，LOTHがよい性能
  - 予測を考慮したスケジューリングの性能はあまり良くない
  - Loadの性能は悪い
- シミュレーション
  - LOTHで適切にスケジューリング
  - 予測したものの性能はあまり良くない→ 予測が不十分
  - RRの性能が悪い

® リソースの状況を適切に予測・考慮することが重要

まとめ

- ジョブ/アプリケーションスケジューリングを統合するフレームワークを提案
- Ninf MetaServer アーキテクチャの実装
- スケジューリング手法の評価
  - サーバの性能・負荷，通信スループットを適切に考慮したスケジューリングが有効
  - リソースの干渉が性能低下に大きく影響
  - 適切なリソース予測が重要

今後の課題1

- Network Taskスケジューリングの評価
  - シミュレータによる大規模評価
    - シミュレーションの信頼性の向上 ― ネットワーク
    - 実際のアプリケーションのWork Load を考慮
- Job / Application Resource Allocatorの実現
  - 既存のグローバルスケジューリングシステムとの比較
  - 最適なスケジューリング手法の提案

今後の課題2

- **計算サーバの性能指標**
  - アープリケーションや問題サイズにより，マシンの性能が異なる

  ® 問題の性質，サイズ，通信パターンなどとを考慮
- **Requestの混雑度とスケジューリング**
  - リソースを共有するRequest が頻繁に発生すると，LOTHで適切なスケジューリングが行えない

  ® 適切なリソースの予測